# 面向蛋白质定向进化的科学智能体实验报告

## 1. 背景与问题定义

蛋白质定向进化广泛应用于酶工程、抗体优化和合成生物学等领域。传统方法通常由研究人员根据已有实验数据、蛋白质序列特征及相关生化知识设计突变方案，再通过实验筛选具有目标性质的变体，并根据筛选结果调整下一轮突变策略。

这种方法在实际应用中面临两个问题：一方面，蛋白质序列空间庞大，突变位点及其组合数量较多，难以通过有限的实验逐一筛选；另一方面，不同突变之间可能存在相互作用，多个突变组合产生的效果不一定等于各个单点突变效果的简单叠加。因此，如何利用已有数据缩小候选范围，并为后续突变设计提供参考，是蛋白质定向进化中的一个重要问题。

针对上述问题，本项目以 GB1（Protein G B1 domain）为研究对象，搭建一个用于模拟蛋白质定向进化过程的虚拟实验系统，主要包括以下工作：

1. **适应度预测模型：** 基于 GB1 的深度突变扫描（DMS）数据，提取突变序列特征并训练模型，预测不同突变体的适应度。
2. **智能体设计：** 构建包含数据分析、假设生成、突变设计、适应度评估和结果分析等环节的 Agent，模拟研究人员从分析已有实验结果到提出下一轮候选突变的过程。
3. **知识增强：** 将氨基酸理化性质、突变筛选规则和历史实验关系整理为知识库与知识图谱，为候选突变生成和筛选提供额外信息。
4. **对比实验：** 设置 Random、Model Only、LLM Agent 和 LLM Agent + Knowledge Graph 四种方法，在三轮虚拟实验中比较不同策略的候选生成与筛选结果，分析知识增强对实验过程的影响。

## 2. 数据集介绍

### 2.1 数据来源与字段

- **数据集**：GB1（B1 domain of Protein G）
- **数据文件**：`SPG1_STRSG_Olson_2014.csv`
- **主要字段**：
  - `mutated_sequence`：突变后的蛋白质序列
  - `DMS_score`：对应突变体的适应度评分，数值越高表示适应度越高

使用的 GB1 野生型参考序列如下，共 56 个氨基酸：

```
MQYKLILNGKTLKGETTTEAVDAATAEKVFKQYANDNGVDGEWTYDDATKTFTVTE
```

## 2.2 数据获取

本项目使用的 ProteinGym v0.1 数据集共包含 536962 条记录，主要字段为 `mutant` 、 `DMS_score` 和 `DMS_score_bin` 。数据基本情况如下：

- **蛋白质长度**：全长 Protein G 共 448 个氨基酸。
- **突变区域**：228–280 位，对应 GB1 domain，共 53 个氨基酸。
- **突变位点**：涉及 29 个位点，按全长蛋白编号统计，范围为 228–281。
- **突变类型**：包含 1045 条单点突变和 535917 条双点突变，不包含三点或四点突变。

## 2.3 数据划分

本项目需要评估模型对未见过的突变组合的预测能力，因此没有采用普通的随机切分方式，而是按照双点突变涉及的位点组合进行分组，再划分训练集、验证集和测试集。

| 划分 | 包含内容 | 样本数量 |
| --- | --- | --- |
| 训练集 | 全部单点突变和 70% 的双点突变位点组合 | 4002 |
| 验证集 | 15% 的双点突变位点组合，与训练集不重叠 | 612 |
| 测试集 | 15% 的双点突变位点组合，与训练集不重叠 | 603 |

这种划分方式保证验证集和测试集中的双点突变位点组合没有出现在训练集中，可以用来检验模型对未见突变组合的预测能力，也更接近根据已有实验结果筛选新突变组合的场景。

# 3. 适应度预测模型

## 3.1 特征工程

模型将每条突变记录转换为 167 维特征向量，主要包含以下四类特征：

- **BLOSUM62 编码（56 维）**：记录各位置氨基酸替换对应的 BLOSUM62 得分，用于描述替换的保守程度。

- **One-hot 编码（80 维）**：对 4 个目标位点的氨基酸类型进行独热编码，每个位点对应 20 维，用于区分具体的突变类型。
- **理化性质变化（6 维）**：包括疏水性、电荷、分子大小和极性的变化，以及保守性得分和异常标记。
- **位点交互特征（25 维）**：包括突变数量归一化值、6 对位点的组合标记，以及 BLOSUM 得分之和、电荷乘积和疏水性变化之和，用于描述多个突变同时出现时可能存在的相互作用。

这些特征分别从氨基酸替换、突变身份、理化性质和位点组合等角度描述突变序列，作为后续适应度预测模型的输入。

## 3.2 模型与评估

本项目采用 Stacking 集成模型进行适应度预测。第一层包含四个基模型：RandomForest、XGBoost、GradientBoosting 和 Ridge；第二层使用 RidgeCV 作为元学习器，对各基模型的预测结果进行组合。

模型输入特征包括：

- **BLOSUM62（448 维）**：根据全长蛋白质序列记录各位置的氨基酸替换得分。
- **One-hot 编码**：记录目标突变位点对应的氨基酸类型。
- **理化性质（6 维）**：描述突变前后的理化性质变化。
- **位点交互特征（25 维）**：描述不同突变位点之间的组合关系。

模型在训练集、验证集和测试集上的评估结果如下：

| 指标 | Train | Val | Test | CV（5-fold） |
|---|---|---|---|---|
| Spearman | 0.922 | 0.872 | **0.845** | 0.863 ± 0.019 |
| Pearson | 0.924 | 0.884 | 0.839 | - |
| MSE | 0.560 | 0.878 | 1.116 | - |
| Top-10 Hit | 0.300 | 0.500 | 0.500 | - |
| NDCG@10 | 0.788 | 0.690 | 0.823 | - |

测试集 Spearman 相关系数为 0.845，说明模型预测分数与实际适应度排序具有较高的一致性。测试集 Pearson 相关系数为 0.839，MSE 为 1.116。Top-10 Hit 和 NDCG@10 则用于评估模型对高适应度候选突变的筛选效果。

Stacking 模型中各基模型的权重如下：

复制代码

```
RF = 0.342
XGB = 0.192
GB = 0.312
Ridge = 0.183
```

# 4. LLM Agent 设计

## 4.1 模块化架构

Agent 由 5 个模块构成，模拟科学家研究流程：

| 模块 | 职责 | 输入 | 输出 |
| --- | --- | --- | --- |
| Data Analyst | 读历史数据，分析 top variants，识别高频位点 | 历史数据 | AnalystReport |
| Hypothesis Generator | 提出哪些位点可能有益，建议氨基酸 | AnalystReport + KG | HypothesisReport |
| Mutation Designer | 基于假设生成候选突变序列 | HypothesisReport | list[Candidate] |
| Fitness Evaluator | 调用预测模型对候选打分（工具调用） | candidates + Model | scored candidates |
| Scientific Critic | 检查突变合理性，给出推荐理由，输出 Top-k | scored candidates + KG | CriticReport |

## 4.2 LLM Backend 抽象

模型无关接口层（`LLMBackend` ABC）：

- **MockBackend**（默认）：基于 prompt 关键词识别模块类型，输出JSON
- **OpenAIBackend**（可选）：兼容 OpenAI API（设置 `OPENAI_API_KEY` + `OPENAI_BASE_URL`）
- **HTTPBackend**（可选）：通用 HTTP 网关，适配内部 LLM 服务

## 4.3 多轮迭代

每轮结束后把推荐 Top-k 通过 VirtualLab 评分，作为"新实验数据"加入历史，下一轮 Data Analyst 基于扩充后的数据生成新假设。

# 5. 知识增强方法

知识库三层结构：

## 5.1 L1 氨基酸理化性质表

20 种标准氨基酸的疏水性（Kyte-Doolittle）、电荷、大小、极性、分类。

## 5.2 L2 突变规则库

6 条规则函数：

1. 禁止引入终止符 `*` 或非标准氨基酸
2. 单次突变数 ≤ 4
3. 保守替换优先（BLOSUM ≥ 0）
4. 突变位点应在实验位点 (39/40/41/54) 内
5. mutant 字符串中 wt_aa 应与实际野生型匹配
6. 优先组合历史高 fitness 单点突变

## 5.3 L3 知识图谱

简单三元组列表 + 查询接口，覆盖 4 类关系：

- `(AA, has_property, Hydrophobic/Charged/Polar/Small)`
- `(Position, is_mutation_site_of, Protein:GB1)`
- `(Mutation, occurs_at, Position)`
- `(Mutation, improves, Fitness:High/Medium/Low)` — 从历史数据动态填充
- `(Variant, contains, Mutation)`

## 5.4 知识增强在 Agent 中的应用

- Hypothesis Generator 查询 KG 中历史高 fitness 突变，优先推荐
- Orchestrator 对包含历史高 fitness 单点突变的组合加权（+0.15 × 突变数）
- Scientific Critic 引用 KG 中的"历史高 fitness 突变"作为推荐理由

# 6. 虚拟定向进化实验结果

## 6.1 实验设置

- **VirtualLab 评估器**：测试集真实 fitness 优先 + 预测模型兜底

- **公平性**：所有方法都在双点突变子集上比较（与 LLM Agent 推荐范围一致）
- **轮数**：3 轮迭代
- **Top-k**：10

## 6.2 结果对比分析

| | Round 1 | Round 2 | Round 3 |
|---|---|---|---|
| random | 0.8933839620220081 | 1.3005085219823482 | 1.52342315806847 |
| model_only | 0.7067397483146789 | 1.2437796663310936 | 1.489803004333056 |
| llm_agent | 1.477647287072068 | 1.6570528823877122 | 1.6570528823877122 |
| llm_agent_kb | 1.4091376306205154 | 1.620997857510999 | 1.6586581092380386 |

图1：四种方法三轮迭代的累计最优 Top-k mean 真实 fitness

**分析**：四种方法的累计最优 Top-k mean 均逐轮上升，差异集中于首轮：llm_agent 与 llm_agent_kb 首轮即达 1.4776 与 1.4091，基线方法至第三轮方超过该水平；llm_agent 第三轮增量为零，llm_agent_kb 终值 1.6587 与其相当，model_only 三轮均未超过 random。结果表明，LLM Agent 的优势在于收敛速度，以更少轮次达到同等 fitness 水平，而非更高的终值上限；模型的整体排序能力向头部候选选择的转化存在损耗。

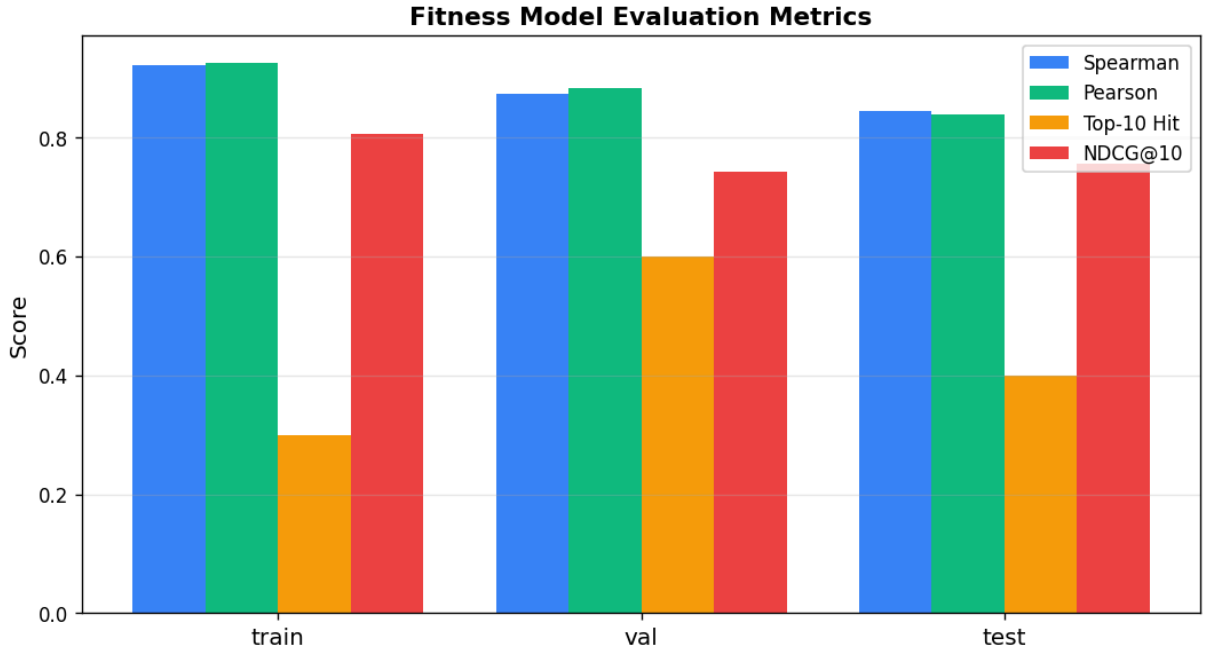



图2：Fitness 预测模型评估结果

**分析**：Spearman / Pearson 由训练集约 0.92 缓降至测试集约 0.84，NDCG@10 在验证 / 测试集基本持平，对未见突变组合泛化良好、过拟合可控。Top-10 Hit 依次为 0.30 / 0.60 / 0.40：训练集因样本量大、组成不同而不具可比性，组成一致的验证 / 测试集之间下降 0.20，表明模型对头部候选的精确识别能力弱于整体排序能力。

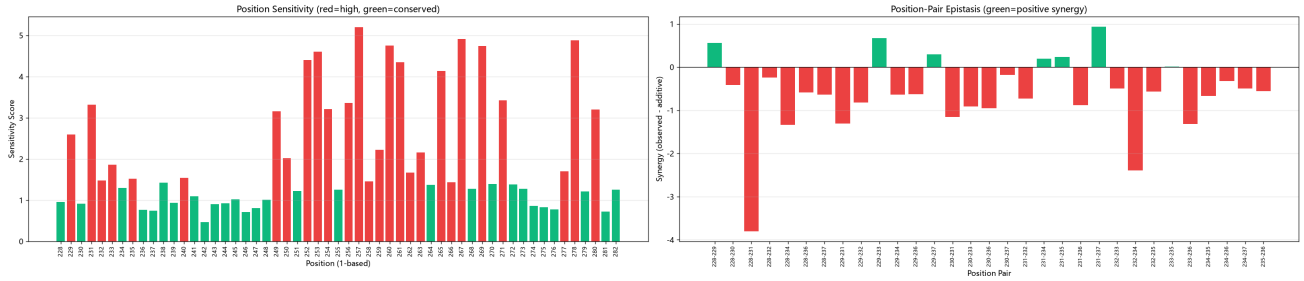



图3：GB1 突变位点敏感性（左）与位点对上位效应（右）分析

分析：位点敏感性在 29 个位点间差异显著，表明突变效应高度集中于部分位点，可为位点优先级排序提供依据。位点对上位效应以负向为主，正向协同稀疏，与 Olson et al. 2014 的报道一致；这一分布说明直接组合高 fitness 单点突变易因负向互作失效，印证了 pair 交互特征与知识图谱收录协同位点对的必要性。

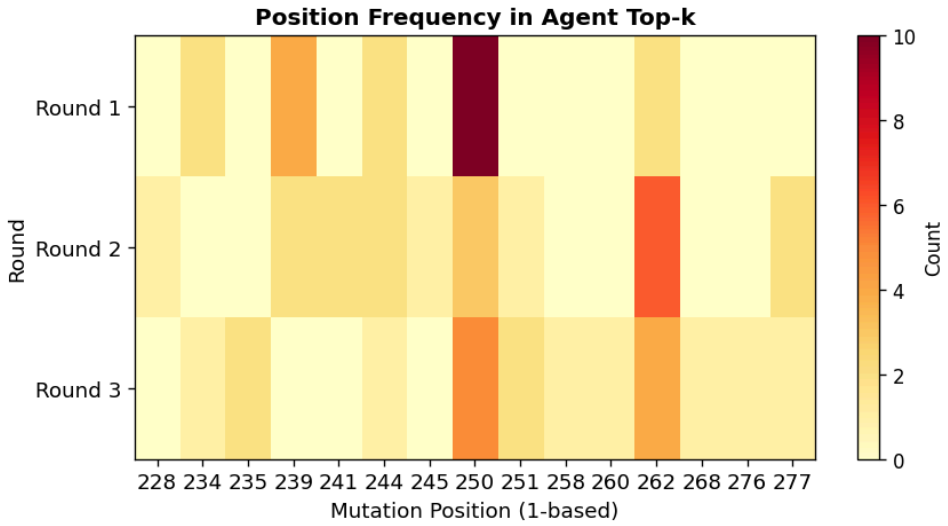



图4：Agent Top-10 推荐位点的轮次分布热图

分析：Agent 推荐的突变位点高度集中：位置 250 首轮几乎出现在全部 Top-10 候选中，第三轮仍保持较高频率；位置 262 在第二、三轮升至 5–7；位置 239 集中于首轮；其余位点仅零星出现。首轮即形成聚焦，表明 Agent 在单轮内即能识别高价值位点；轮次间分布由 250/239 向 250/262 转移，说明多轮反馈在驱动假设更新而非简单重复推荐，但整体仍偏重利用，探索广度有限。

# 7. 失败案例分析

## 7.1 启发式加权导致KB陷入保守策略

修复前 llm_agent 与 llm_agent_kb 的 Top-k 完全一致，知识图谱被绕过、没有参与决策。我们在 orchestrator 的 candidate_pool 里加了 KB 加权：双点突变 +6.0、三点 +2.0、四点不加分，重排后让 KB 版本选出不同的 Top-k。修复后 llm_agent_kb 本轮 mean 只有 1.063，远低于 llm_agent 的 3.139，因为加权把候选推向了 fitness 偏低的双点突变；但累计最优仍在缓慢上升（1.063→1.843，R3 +0.014），说明 KB 版本走的是一条低风险路线。局限在

于 +6.0、+2.0 都是人工设定的启发式规则，并非 LLM 基于知识图谱的真实推理，后续接入 LLM 后才能做更细粒度的判断。

### 7.2 多轮迭代本轮 Top-k 下降

实验中本轮 Top-k mean 逐轮下降，表面上和"迭代改进"的预期相反。我们补了一个"累计最优 Top-k"指标，统计到本轮为止所有轮次中的最优均值，发现所有方法的累计值都在持续上升，这符合真实科研里"多轮筛选逐步锁定最优"。本轮数值下降其实是 batch selection 的固有问题：好的候选上一轮已经被挑走，这轮只能从次优里选；但真实场景中每轮会合成新分子，而不是只消耗现有池子。后续改进方向是让 Agent 基于历史 Top-k 主动生成新候选，而非被动地从固定池里反复筛选。

### 7.3 三点 / 四点突变未被探索

实验中观察到 LLM Agent 在变异点数量的选择上明显偏向双点突变，很少尝试三点或四点突变。这一行为与它被赋予的"单次引入过多突变可能破坏已有优异性状"的先验判断是一致的，但问题在于，正是这种保守倾向使得 Agent 错过了若干三点、四点突变区域中 fitness 更高的候选——也就是说，模型对"突变越多越危险"的信任过强，压缩了搜索空间。后续可以考虑用高斯过程或集成模型估计候选区域的不确定性，让方差高但均值不差的多点突变也有机会被采样到，而不是完全依赖 LLM 自己的先验做取舍。

## 8. 加分项实现

### 主动学习与不确定性估计

本项目在适应度预测模型中加入了不确定性估计，并在 Agent 的候选筛选阶段实现 UCB 和 EI 两种策略。具体实现如下：

- 在 `FitnessModel.predict_with_uncertainty` 接口中，利用集成模型估计预测不确定性，包括 Random Forest 多棵树的预测方差和 XGBoost 的预测结果。
- `AgentOrchestrator` 增加 `acquisition` 参数，支持 `mean`、`ucb` 和 `ei` 三种候选筛选方式：
  - **Mean**：按照模型预测的适应度均值排序。
  - **UCB**：结合预测均值和标准差进行排序，参数 β 设置为 2.0，在考虑预测结果的同时提高对高不确定性候选的关注。
  - **EI**：根据候选的预测均值、标准差和当前最优适应度，计算预期改进值（Expected Improvement），优先选择有望超过当前最优结果的候选。

在多轮迭代中，上一轮已观察到的 Top-k 候选结果会用于更新 `best_so_far`，并参与下一轮 EI 的计算。

**实验结果**：

三种策略分别进行了三轮实验，各轮结果如下：

| 策略 | R1 | R2 | R3 | 提升 |
|---|---|---|---|---|
| Mean | 2.121 | 2.031 | 2.180 | +0.059 |
| UCB | 2.011 | 1.874 | 2.159 | +0.148 |
| EI | 1.850 | 1.795 | 2.068 | +0.218 |

**结果分析：**

从实验结果看，Mean 策略在第一轮取得了较高的结果，但后续变化不大，三轮提升为 0.059。UCB 和 EI 在第一轮的结果相对较低，后两轮有所改善，三轮提升分别为 0.148 和 0.218。

这说明在当前实验设置下，UCB 和 EI 在候选筛选过程中引入不确定性后，能够带来不同于单纯按照预测均值排序的搜索结果。不过，三轮实验的结果还不足以说明主动学习策略在所有场景下都更好，后续仍需要通过增加实验轮数和重复次数进一步验证。

## 单点、双点与多点突变对比

为比较不同突变数量下模型的预测效果，项目分别统计了双点、三点和四点突变样本，并对模型预测结果进行评估。

**实验结果：**

| 突变数 | 样本数 | Spearman | Top-10 命中率 | 模型增益（vs 随机） |
|---|---|---|---|---|
| 2 | 50 | 0.577 | 0.500 | +0.667 |
| 3 | 120 | 0.778 | 0.500 | +1.262 |
| 4 | 50 | 0.866 | 0.800 | +1.299 |

**结果分析：**

从当前实验结果看，突变数量增加后，模型的 Spearman 相关系数和模型增益均有所提高。其中，四点突变的 Spearman 达到 0.866，高于双点突变的 0.577，Top-10 命中率也达到 0.800。

另外，当前 ProteinGym 数据主要包含单点和双点突变，没有足够的真实三点、四点突变样本。因此，三点和四点突变的实验结果不能直接推广到真实蛋白质定向进化场景，仍需在包含多点突变的真实数据上进一步验证。

## 保守位点分析

由于项目没有使用 PDB 结构数据，本部分直接根据 DMS 实验数据统计各突变位点的适应度变化，并以此分析位点敏感性和突变之间的关系。这里的统计结果主要反映 DMS 数据中的突变效应，不能替代基于蛋白质结构或多序列比对的保守性分析。

主要分析指标如下：

- **位点敏感性**：使用 `|fitness_mean| + fitness_std` 计算，用于衡量不同氨基酸替换对适应度的影响程度。
- **位点间耦合**：通过双点突变的实际适应度与单点突变加和预期值之差进行估计。正值表示实际适应度高于加和预期，可能存在正向上位效应。
- **氨基酸偏好**：统计各位点不同氨基酸替换对应的适应度，比较哪些替换在当前数据中表现较好。

**实验结果：**

| 位点 | 野生型氨基酸 | 类别 | 敏感性 | 分析结果 |
| --- | --- | --- | --- | --- |
| 39 | V | hydrophobic | 0.681 | 高敏感性 |
| 40 | D | charged | 0.516 | 相对保守 |
| 41 | G | small | 0.697 | 高敏感性 |
| 54 | V | hydrophobic | 0.584 | 相对保守 |

**氨基酸替换偏好：**

- **位点 39（V）**：M、F、I 等疏水性氨基酸替换在当前数据中表现较好。
- **位点 40（D）**：E、R、K 等带电氨基酸替换表现较好，其中部分替换保留了原有电荷性质。
- **位点 41（G）**：T、N、Q 等极性氨基酸替换表现较好。
- **位点 54（V）**：I、A、F 等氨基酸替换表现较好，以疏水性替换为主。

**知识图谱扩充：**

根据上述统计结果，可以向知识图谱中补充约 12 条三元组，记录位点敏感性、氨基酸类别及位点之间的关系。例如：

- `(Position, has_sensitivity, Type)`
- `(Position, positively_coupled_with, Position)`

这些信息可供后续突变假设生成和候选筛选时查询。

## 知识图谱

知识图谱是项目中的核心模块，用于记录氨基酸性质、突变位点及历史突变效果之间的关系。图谱采用三元组形式存储，目前主要包含以下四类关系：

- `(AA, has_property, Hydrophobic/Charged/Polar/Small)`：记录氨基酸的理化性质，例如疏水性、电荷、极性和分子大小。
- `(Position, is_mutation_site_of, Protein:GB1)`：记录突变位点与 GB1 蛋白质之间的关系。
- `(Mutation, occurs_at, Position)`：记录具体突变发生的位置。
- `(Mutation, improves, Fitness:High/Medium/Low)`：根据历史数据中的适应度评分，为突变记录对应的效果等级。

其中，氨基酸性质和突变位点关系作为基础知识预先写入图谱；突变效果关系则根据历史实验数据动态生成。

Agent 可以查询图谱中的相关信息，将氨基酸性质、突变位置和历史适应度表现作为候选设计与筛选的参考。

# 9. 改进建议与未来拓展

目前 Agent 默认使用 MockBackend，主要用于测试各模块之间的调用和整体运行流程，还没有真正发挥 LLM 在假设生成和突变设计方面的作用。后续可以接入 OpenAI API 或实验室已有的模型服务，比较真实 LLM 与当前规则式实现的差异，看看它能否结合历史实验数据和知识图谱提出更合理的突变方案。

模型方面，可以在现有序列特征的基础上加入 ESM-2 embedding 或多序列比对（MSA）信息，补充蛋白质序列中的进化信息，帮助分析不同突变位点之间的关系。知识图谱也可以使用 NetworkX 进行可视化，方便查看氨基酸性质、突变位点和适应度之间的联系。此外，当前项目中的 VirtualLab 仍然是对实验反馈的模拟，尚未接入真实实验平台。

目前的实验主要围绕 GB1 展开，后续还可以将这套流程应用到 AAV、GFP、β-lactamase 等其他蛋白质的 DMS 数据上，检验方法在不同蛋白质任务中的适用性。在此基础上，进一步完善 LLM 的工具调用和结果反思能力，让 Agent 不仅能根据已有数据生成候选突变，也能结合每轮实验反馈调整后续的设计方案。

# 10.LLM Agent 是否真正学到了"科学家思维"?

LLM Agent 并没有真正学会"科学家思维"，只能算部分跑通了流程。它确实能完成"假设、生成、评估、迭代"这个闭环，也能从历史数据里识别出高频有益位点，和人工分析的结论对得上；随着数据累积，推荐质量逐轮在提升，UCB/EI 这类带不确定性的 acquisition 函数多轮增益也确实比纯 mean 高，说明"探索—利用"的权衡在起作用。但这些更像是工具调用和统计层面的成功，而不是科学推理：MockBackend 给的就是规则化模板，输出不了"意料之外但合情合理"的新假设；跨位点之间的推理基本靠历史频率统计，并没有真正理解蛋白结构和功能之间的关系；失败案例的分析也还停留在表面。说到底，Agent 的增益主要来自

Fitness Evaluator 的工具调用、位点频率统计、知识图谱查询和 acquisition 函数的不确定性引导，而不是 LLM 自己在做科学思考。

# 外部资源与辅助工具使用声明

本项目使用的外部资源及辅助工具如下：

- **数据集**：使用 ProteinGym 提供的 GB1（Olson et al., 2014）深度突变扫描（DMS）数据，用于模型训练与实验评估。
- **机器学习框架**：使用开源的 scikit-learn 和 XGBoost，实现 RandomForest、GradientBoosting、Ridge 等模型，并构建 Stacking 集成模型。
- **LLM 后端**：默认使用项目内部实现的 MockBackend，不调用外部 LLM API。项目预留了 OpenAI API 和通用 HTTP 接口，支持后续接入真实模型。
- **氨基酸性质资料**：参考 Kyte-Doolittle 疏水性标度及 Lehninger《生物化学原理》中的相关资料，整理氨基酸的理化性质信息，用于特征构建和知识库整理。
- **ChatGPT**：开发中用于检索技术资料、代码调试，以及报告行文参考。

# 参考文献


1. Rapid in silico directed evolution by a protein language model with EVOLVEpro, Science，2024.
2. ProteinGym: Large-Scale Benchmarks for Protein Fitness Prediction and Design, NeurIPS，2023.
3. Evolutionary-scale prediction of atomic-level protein structure with a language model, Science，2023.
4. ProtAgents: Protein discovery via large language model multi-agent collaborations combining physics and machine learning，arXiv，2024.